

# Relatório Comparativo de Classificadores: KNN vs. MLP

## Objetivo

Comparar o desempenho dos algoritmos K-Nearest Neighbors (KNN) e Multi-Layer Perceptron (MLP) na classificação dos datasets Iris e Wine, utilizando as métricas de acurácia, precisão e revocação.

## Metodologia

A análise foi executada conforme o notebook fornecido, que realiza a normalização dos dados (`StandardScaler`) e a divisão em conjuntos de treino (70%) e teste (30%). Os modelos foram configurados como KNN ( $k=5$ ) e MLP (rede neural de 2 camadas).

## Resultados Consolidados

A tabela abaixo resume o desempenho de cada modelo no conjunto de teste:

Dataset	Modelo	Acurácia	Precisão (Ponderada)	Revocação (Ponderada)
Iris	MLP	0.689	0.839	0.689
Iris	KNN	<b>0.911</b>	<b>0.930</b>	<b>0.911</b>
Wine	MLP	0.815	0.815	0.815
Wine	KNN	<b>0.944</b>	<b>0.954</b>	<b>0.944</b>

## Análise e Conclusão

O classificador **KNN demonstrou performance notavelmente superior em ambos os cenários**. No dataset Iris, a acurácia do KNN (91.1%) superou massivamente a do MLP (68.9%), que falhou em distinguir a classe `versicolor` (recall de apenas 7%). No dataset Wine, a vantagem do KNN se manteve (94.4% vs 81.5%).

A superioridade do KNN confirma que para datasets pequenos e bem-estruturados, como os analisados, um algoritmo mais simples pode ser mais eficaz. A complexidade do MLP se mostrou uma desvantagem, provavelmente pela quantidade limitada de dados para um treinamento robusto. A análise reforça que a escolha do modelo deve sempre se adequar às características do problema, pois a complexidade não garante um melhor resultado.